

Nome: Luis Hikaru Saito Silva 10297780  
Iggor Francis Numata Mathews 10262572

## MAC0460 - Aprendizado de Máquina – ep3: Relatório

### Implementação

O código das funções `logistic_fit()` e `logistic_predict()` foi cuidadosamente comentado e a maioria dos detalhes sobre implementação é melhor entendida se vista diretamente no arquivo `ep3.py`.

Ainda assim, alguns detalhes devem ser destacados. As funções, pelo visto nos testes, funcionam em aproximadamente 80% das execuções. Em alguns casos, dependendo do vetor  $X$  recebido e dos valores iniciais de  $w$  gerados aleatoriamente, há um overflow que faz com que números muito grandes (na ordem de  $10^{200}$ ) ou n.a.n. apareçam em  $w$ . Os resultados variam em arquiteturas computacionais diferentes.

Não conseguimos encontrar uma solução para o problema, sendo que tentamos arredondamentos, simplificações e outros métodos para calcular o gradiente do erro, sem sucesso em nenhum deles.

Para a elaboração dos programas, consultamos os slides da aula, assim como as vídeo-aulas da *Caltech* e alguns sites comuns para esclarecimentos em relação à linguagem python. A função teste foi feita com base no código apresentado pelo aluno Leonardo Banger no fórum de discussão da matéria.

### Testes

Diversos testes foram realizados sobre o programa. Para melhor visualização, foi elaborado um gráfico que colore de azul pontos “classificados” de forma correta e em vermelho pontos “classificados” incorretamente. Essa classificação foi alterada durante os testes para melhor entender os resultados.

Por exemplo, se o critério for: para  $Y = 1$  predição  $> 50\%$ ,  $Y = -1$  predição  $< 50\%$  -> sucesso, a grande maioria do gráfico é colorida de azul. Dessa forma, quanto mais restritas as margens, maior é a quantidade de pontos classificados incorretamente, indicando que pontos na área de intersecção entre duas distribuições possuem maior “grau de incerteza” do que pontos distantes da área de intersecção, que é uma boa performance para o algoritmo.